

Contents

Primer Parcial	2
1. Preliminar	2
1.1. Propiedades de la dimensión	2
1.2. Inversible (y vectores LI inealmente independientes)	2
1.3. Propiedades matriciales	2
1.4. Subespacios	3
1.5. Generadores y base	4
2. Transformaciones Lineales y Cambio de Base	4
2.1. Definición y Propiedades Básicas	4
2.2. Núcleo e Imagen	4
2.3. Representación Matricial de una T.L.	4
2.4. Matriz de Cambio de Base (Vectores)	5
2.5. Cambio de Base en Transformaciones Lineales	5
3. Proyecciones	6
3.1. Proyecciones en General	6
3.2. Proyección Ortogonal	6
3.3. Ortonormalizar una matriz	7
4. Normas	8
4.1. Normas vectoriales	8
4.2. Normas matriciales	8
$\ A\ = \sup_{v \neq 0} \left\{ \frac{\ Av\ }{\ v\ } \right\}$	9
4.3. Condición y propiedades	9
5. Descomposición $A = LU$	9
5.1 Existencia	10
5.2 Algoritmo	10
5.3 Descomposición $PA = LU$	10
6. Descomposición Cholesky $A = \hat{L}\hat{L}^T$	10
6.1 Existencia	10
6.2 Algoritmo	10
7. Descomposición $A = QR$	11
7.1 Existencia	11
7.1 Algoritmo HouseHolder	11
7.3 Algoritmo con Gram-Schmidt	11
8. Teoremas y propiedades	12
8.1. Definida positiva	12
8.3 Semidefinida positiva	12
8.3. Diagonalizable	12
8.4. Multiplicidades	12
8.5. Matrices semejantes	13

Primer Parcial

1. Preliminar

1.1. Propiedades de la dimensión

- **Teorema de la dimensión:** $\dim(\text{Im}(A)) + \dim(\ker(A)) = n$, donde n es el número de columnas de A .
- $\dim(A + B) = \dim(A) + \dim(B) - \dim(A \cap B)$.
- $\text{rk}(A) = \dim(\text{Im}(A)) =$ “cantidad de ecuaciones li del sistema”.
- $\dim(\ker(A)) = n - \text{rk}(A)$.
- $\ker(A) = \{x : Ax = 0\}$.
- **Teorema:** V espacio de dim finita, $f : V \rightarrow W$ una tl. Sup. $\ker(f)$ tiene a B como base y $B' = B \cup C$ una completación de una base de V con $C \cap B = \emptyset$, entonces $f(C)$ es una base de W

1.2. Inversible (y vectores LI inealmente independientes)

A singular -

$$\begin{aligned} & A \text{ no es inversible} \\ \Leftrightarrow \lambda = 0 & \text{ es autovalor} \\ \Leftrightarrow \det(A) = 0 \\ \Leftrightarrow \dim(\text{Nu}(A)) > 0 \\ \Leftrightarrow & \text{ Los vectores columna de A son LD} \end{aligned}$$

A invertible -

$$\begin{aligned} & A \text{ invertible} \\ \Leftrightarrow \det(A) \neq 0 \\ \Leftrightarrow & \text{ Los vectores columna de A son LI} \end{aligned}$$

Caso particular - $A \in K^{N \times N}$ invertible $\Leftrightarrow$

Los vectores columna de A forman una base - A estrictamente diagonal dominante (la diafonal es mayor en A invertible

1.3. Propiedades matriciales

- Cualquier matriz $A \in \mathbb{K}^{n \times n}$ puede escribirse como $A = \sum_i \sum_j a_{ij} E_{ij}$, siendo E_{ij} la matriz definida por

$$E_{ij} = \begin{cases} 1 & \text{si } i=j \\ 0 & \text{cc.} \end{cases}$$

1.4. Subespacios

Un subespacio debe cumplir que: - [1] $0 \in S$ - [2] $v \in S, w \in S \implies v + w \in S$ - [3] $\forall k \in \mathbb{K}, s \in S, ks \in S$

Más propiedades: - **Suma de subespacios:** Sean S y T subespacios con generadores $\{s_0, \dots, s_i\}$ y $\{t_0, \dots, t_j\}$. Entonces, la suma $S + T$ es el subespacio generado por la unión de sus generadores:

$$S + T = \langle s_0, \dots, s_i, t_0, \dots, t_j \rangle$$

- **Intersección de subespacios:** Dados S y T generados por los conjuntos $\{s_0, \dots, s_i\}$ y $\{t_0, \dots, t_j\}$ respectivamente, la intersección $S \cap T$ es el conjunto de vectores que pueden escribirse tanto como combinación lineal de los generadores de S como de los de T :

$$S \cap T = \{v : v \in S \text{ y } v \in T\}$$

Para encontrar el conjunto, se resuelve el sistema $S\alpha = T\beta$ con variables libres α y β , es decir, se buscan los vectores que pueden escribirse en ambos sistemas de generadores simultáneamente. Alternativamente, $S \cap T$ es el subespacio generado por todos los vectores comunes a ambos subespacios.

Forma matricial: Si representamos las matrices S (con columnas los generadores de S) y T (con columnas los generadores de T), la intersección $S \cap T$ puede obtenerse encontrando todas las soluciones del sistema homogéneo $S\alpha - T\beta = 0$, es decir:

$$(S \ -T) \begin{pmatrix} \alpha \\ \beta \end{pmatrix} = 0$$

Luego, los vectores de la forma $S\alpha$ (o $T\beta$) que satisfacen esta ecuación constituyen la intersección $S \cap T$. Así, se puede obtener una base del subespacio intersección de manera algorítmica usando métodos matriciales.

- **Suma Directa:** La suma $L + M$ es directa ($L \oplus M$) si, y sólo si, $L \cap M = \{0\}$.
- **Unión de subespacios:** $S \cup T = \{w : w \in S \vee w \in T\}$, aunque en general la unión de subespacios no es un subespacio salvo casos triviales.
- **Subespacio contenido:** Si $S = \langle s_0, \dots, s_i \rangle$, entonces $S \subset T$ si y sólo si $\forall s_j : s_j \in T$.
- Se verifica que $A \cap B = \{0\}$ comprobando que no es posible expresar los generadores de un subespacio como combinaciones lineales de los generadores del otro.
- **Subespacios ortogonales:** Dos subespacios S y T son ortogonales si todo generador de S es perpendicular a todo generador de T (y viceversa).
- El subespacio ortogonal de S se denota:

$$S^\perp = \{v \mid \langle v, s \rangle = 0, \forall s \in S\}$$

1.5. Generadores y base

- Para obtener una base a partir de generadores puedo poner los vectores en filas, triangular la matriz y ver que, las filas que se vuelven 0 podemos sacarlas, y si se vuelven CL sacar 1.
- Para extender generados para formar una base puedo alinear los vectores como filas y completar las filas para que la matriz triangulada quede LI.

2. Transformaciones Lineales y Cambio de Base

Esta sección unifica el concepto abstracto de función lineal con su implementación práctica a través de matrices y coordenadas.

2.1. Definición y Propiedades Básicas

Sean $\mathbb{V}$ y $\mathbb{W}$ dos $\mathbb{K}$ -espacios vectoriales. Una función $f : \mathbb{V} \rightarrow \mathbb{W}$ es una **Transformación Lineal** si conserva la estructura de espacio vectorial, es decir:

$$f(\alpha u + v) = \alpha f(u) + f(v), \quad \forall u, v \in \mathbb{V}, \forall \alpha \in \mathbb{K}$$

Propiedades inmediatas:

1. **El cero va al cero:** $f(0_{\mathbb{V}}) = 0_{\mathbb{W}}$.
2. **Inversos aditivos:** $f(-v) = -f(v)$.
3. **Preservación de combinaciones lineales:** $f(\sum \alpha_i v_i) = \sum \alpha_i f(v_i)$.

2.2. Núcleo e Imagen

Son los dos subespacios fundamentales asociados a una T.L.:

- **Núcleo (Kernel):** Es el conjunto de vectores del dominio que se transforman en el cero.

$$\ker(f) = \{v \in \mathbb{V} : f(v) = 0_{\mathbb{W}}\}$$

- **Propiedad:** f es inyectiva (monomorfismo) $\Leftrightarrow \ker(f) = \{0\}$.

- **Imagen:** Es el conjunto de vectores del codominio que son “alcanzados” por la función.

$$\text{Im}(f) = \{w \in \mathbb{W} : \exists v \in \mathbb{V}, f(v) = w\}$$

- **Propiedad:** f es sobreyectiva (epimorfismo) $\Leftrightarrow \text{Im}(f) = \mathbb{W}$.

Teorema de la Dimensión (Teorema del Rango-Nulidad)

Si $\mathbb{V}$ es de dimensión finita:

$$\dim(\mathbb{V}) = \dim(\ker(f)) + \dim(\text{Im}(f))$$

2.3. Representación Matricial de una T.L.

Toda transformación lineal entre espacios de dimensión finita puede representarse mediante una matriz. La forma de esta matriz depende de las bases elegidas.

Sean $B = \{v_1, \dots, v_n\}$ una base de $\mathbb{V}$ y $B' = \{w_1, \dots, w_m\}$ una base de $\mathbb{W}$.

La **matriz asociada a f en las bases B y B'** , denotada como $[f]_{BB'}$ (o $M(f)_{BB'}$), se construye colocando en sus columnas las coordenadas de las imágenes de los vectores de la base B escritas en la base B' .

$$[f]_{BB'} = \left(\begin{array}{c|c|c} | & & | \\ [f(v_1)]_{B'} & \cdots & [f(v_n)]_{B'} \\ | & & | \end{array} \right)$$

Relación fundamental:

Para transformar un vector v , multiplicamos sus coordenadas por la matriz:

$$[f(v)]_{BB'} = [f]_{BB'} \cdot [v]_B$$

2.4. Matriz de Cambio de Base (Vectores)

Si queremos cambiar las coordenadas de un vector de una base a otra dentro del mismo espacio $\mathbb{V}$:

Sean $B = \{v_1, \dots, v_n\}$ y $B' = \{u_1, \dots, u_n\}$ dos bases de $\mathbb{V}$.

La **Matriz de Cambio de Base de B a B'** , denotada como $C_{BB'}$, cumple que:

$$[v]_{B'} = C_{BB'} \cdot [v]_B$$

Propiedades de $C_{BB'}$:

1. **Construcción:** Las columnas de $C_{BB'}$ son las coordenadas de los vectores de la base “vieja” B escritos en función de la base “nueva” B' .
2. **Inversibilidad:** Toda matriz de cambio de base es inversible.
3. **Inversa:** $C_{B'B} = (C_{BB'})^{-1}$.
4. **Composición:** $C_{BB''} = C_{B'B''} \cdot C_{BB'}$.

Nota práctica: Es fácil construir la matriz de cambio de base C_{BE} (de una base B cualquiera a la canónica E), simplemente poniendo los vectores de B como columnas. Para volver (de canónica a B), calculamos la inversa: $C_{EB} = (C_{BE})^{-1}$. Si B es ortonormal, $C_{EB} = C_{BE}^T$.

2.5. Cambio de Base en Transformaciones Lineales

$$[f]_{BE} = [f]_{EE} C_{BE}$$

- Donde f_{EE} está definida por las ecuaciones dadas de $f(X) = (\phi_1(X), \dots, \phi_n(X))$
- Conclusión Clave:** Dos matrices representan la misma transformación lineal en

distintas bases si y solo si son **semejantes**. Esto implica que comparten propiedades intrínsecas como el determinante, la traza y los autovalores.

3. Proyecciones

Este es el resumen completo de propiedades y teoremas clave sobre proyecciones que necesitas para el examen, completando y formalizando la sección que proporcionaste:

3.1. Proyecciones en General

Una matriz P se llama **Proyector** si, al aplicarse dos veces, el resultado es el mismo que aplicarse una sola vez.

- **Idempotencia:** P es una matriz de proyección $\Leftrightarrow P^2 = P$.
- **Autovalores:** Los autovalores de cualquier matriz de proyección P solo pueden ser 0 o 1 .
- **Relación Núcleo/Imagen (Clave):** Para cualquier proyector P :

$$\text{Im}(P) = \text{Nu}(I - P)$$

$$\text{Im}(I - P) = \text{Nu}(-P) = \text{Nu}(P)$$

(Los vectores en la imagen son los que quedan fijos: $Px = x$).

Armado de proyector en general:

Supongamos tengo un subespacio $M = [v_1 \mid \dots \mid v_n]$

$$PM = R = [p(v_1) \mid \dots \mid p(v_n)]$$

$$P = RM^{-1}$$

3.2. Proyección Ortogonal

Dado un subespacio $S \subset \mathbb{R}^n$, la **Proyección Ortogonal** sobre S , P_S , es la transformación lineal que asocia a cada vector x su vector más cercano en S .

3.2.1. Propiedades Geométricas

- **Vectores en S (Invarianza):** $P_S(s) = s \quad \forall s \in S$
- **Imagen en S:** $P_S(x) \in S \quad \forall x \in \mathbb{R}^n$
- **Vector Error:** El vector error $e = x - P_S(x)$ siempre es ortogonal a S :

$x - P_S(x) \in S^\perp$ o, equivalentemente, $P_S(x)$ es el vector de S más cercano a x

3.2.2. Teorema Fundamental de la Proyección (Descomposición Ortogonal)

Todo vector $x \in \mathbb{R}^n$ puede descomponerse de forma **única** en la suma de dos componentes ortogonales:

$$x = P_S(x) + P_{S^\perp}(x)$$

Donde $P_S(x) \in S$ y $P_{S^\perp}(x) \in S^\perp$.

3.2.3. Propiedades de la Matriz de Proyección

La matriz P_S es una matriz de proyección si y solo si cumple: * **Idempotencia:** $P_S^2 = P_S$ * **Simetría:** $P_S^T = P_S$ (Esta es la condición extra que la hace *ortogonal*). * $Nu(P) \perp Im(P)$

3.2.4. Fórmulas de Construcción

Sea $S = \text{col}(A)$, donde las columnas de A forman una base para S .

Caso	Matriz A (Base de S)	Fórmula del Proyector P_S
Caso General	Columnas de A L.I. (no necesariamente ortonormales)	$P_S = RS^{-1}$
Caso Especial	Columnas de Q ortonormales ($Q^T Q = I$)	$P_S = QQ^T$

Nota Operativa: Si A no tiene columnas ortogonales, usualmente se le aplica **Gram-Schmidt** a las columnas de A para obtener la matriz Q de la base ortonormal, y así usar la fórmula simplificada $P_S = QQ^T$.

3.2.5. Proyector a partir de una BON

Si tienes una **Base Ortonormal (B.O.N.)** de S dada por $\{v_1, \dots, v_r\}$, el proyector ortogonal sobre S es la suma de proyectores de rango uno:

$$P_S = \sum_{i=1}^r v_i v_i^T$$

Y su acción sobre un vector x es:

$$P_S(x) = P_S x = \sum_{i=1}^r \left(\underbrace{v_i^T x}_{\text{proy. sobre } v_i} \right) v_i$$

3.2.6. Proyector Complementario

El proyector ortogonal sobre el complemento ortogonal $S^\perp$ se define como:

$$P_{S^\perp} = I - P_S$$

3.2.7. Relación de Subespacios (matriz de proyección ortonormal)

- $Im(P_S) = S$
- $Nu(P_S) = S^\perp$

3.3. Ortonormalizar una matriz

3.3.1. Proceso (Gram-Schmidt)

Para ortonormalizar una matriz se puede usar Gram-Schmidt.

Algoritmo:

Sea $a_1, \dots, a_n$ las columnas de la matriz origen A .

1. Fijamos $v_1 := a_1$.

2. Para cada $i \in [1..n]$:

- $v_{i+1} = a_{i+1} - \sum_{j=1}^i p_{v_j}(a_{i+1})$

4. Para cada v_i calculado tomamos $v_{i'} = \frac{v_i}{||v_i||}$

Donde: - $p_a(b) = \frac{a^T b}{a^T a} a$

3.3.2. Propiedades de matrices ortonormales

- $Q^T = Q^{-1}$
- Q unitaria, $||Qx|| = ||x||$

4. Normas

4.1. Normas vectoriales

Una norma de un $\mathbb{K}$ -espacio vectorial es una función $||\cdot|| : V \rightarrow \mathbb{R}_{\geq 0}$ que cumple las siguientes propiedades: 1. $||av|| = |a| ||v||$ para $a \in \mathbb{K} \wedge v \in V$

2. Si $||v|| = 0$, entonces $v = 0$. 3.

$$||u+v|| \leq ||u|| + ||v|| \text{ para todo } u, v \in V$$

Ejemplos en $\mathbb{K}^n$:

- Norma-1: $||v|| = |v_1| + \dots + |v_n|$
- Norma-infinito: $||v||_{\infty} = \max \{|v_1|, \dots, |v_n|\}$
- Norma-p: $||v||_p = (|v_1|^p + \dots + |v_n|^p)^{1/p}$

Desigualdad Cauchy-Schwartz:

$$|x^* y| \leq ||x||_* ||y||, \text{ para } x, y \in \mathbb{K}^n$$

Equivalencia entre normas:

Sean $||\cdot||$ y $||\cdot||_*$ dos normas en mismo $\mathbb{K}$ -espacio vectorial V . Son equivalentes si $\exists c, C > 0$ tales que para todo $x \in V$:

$$c ||x||_* \leq ||x|| \leq C ||x||_*$$

Convergencia de un vector a una norma

Sucede si $||v_n - v|| \rightarrow 0$ cuando $n \rightarrow \infty$.

4.2. Normas matriciales

Dada $A \in \mathbb{K}^{n \times m}$ y un par de normas vectoriales $||\cdot||_n$ y $||\cdot||_m$ en $\mathbb{K}^n$ y $\mathbb{K}^m$, la norma inducida (o submultiplicativa) de matrices es:

$$\|A\|_{n,m} = \max_{\substack{x \in \mathbb{K}^m \\ x \neq 0}} \frac{\|Ax\|_n}{\|x\|_m} = \max_{x \in \mathbb{K}^m, \|x\|_m=1} \|Ax\|_n$$

Ejemplos de normas matriciales:

- Norma-infinito: $\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^m |a_{ij}|$ (máx suma filas)
- Norma-1: $\|A\|_1 = \max_{1 \leq j \leq m} \sum_{i=1}^n |a_{ij}|$ (máx suma columnas)

Propiedades:

- $\|Ax\| \leq \|A\| \cdot \|x\|$
- $\|AB\| \leq \|A\| \cdot \|B\|$
- $\|A\| = \sup_{v \neq 0} \left\{ \frac{\|Av\|}{\|v\|} \right\}$

4.3. Condición y propiedades

El **número de condición** (k) de una matriz A respecto a una norma vectorial es:

- $k(A) = \|A\| / \inf_{\lambda \in \sigma(A)} \|\lambda^{-1}\|$

Propiedades importantes del número de condición: -

$$k_*(A) \geq \sup_{\substack{H \\ \text{singular}}} \left\{ \frac{\|A\|_*}{\|A-H\|_*} \right\}$$

-

$$\frac{1}{k_*(A)} \leq \inf_{\substack{H \\ \text{singular}}} \left\{ \frac{\|A-H\|_*}{\|A\|_*} \right\}$$

Relaciones entre normas: - $\frac{1}{\sqrt{n}} \|A\|_\infty < \|A\|_2 < \sqrt{n} \|A\|_\infty$ - $\frac{1}{\sqrt{n}} \|A\|_2 < \|A\|_1 < \sqrt{n} \|A\|_2$ - $\|A\|_\infty < \|A\|_1 < n \|A\|_\infty$

Observación - $k \in [1, +\infty)$ - Un número de condición grande implica que el sistema es mal condicionado y sensible a errores de redondeo.

Error relativo

Se puede acotar el error relativo de computo de x con:

$$\frac{\|x - \tilde{x}\|}{\|x\|} \leq \kappa(A) \frac{\|b - \tilde{b}\|}{\|b\|}$$

—

5. Descomposición $A = LU$

$$A = LU$$

- L : triangular inferior (con la diagonal principal). - U : triangular superior.

5.1 Existencia

Existe LU para matrices cuadradas

$\Leftrightarrow$ durante la eliminación gaussiana, todos los pivotes deben ser distintos a cero (sin intercambiar filas)

$\Leftrightarrow \det(A_k) \neq 0$ para A_k submatriz principal hasta $n-1$ (todos sus menores principales son distintos a 0)

Unicidad La factorización es única si A es invertible.

5.2 Algoritmo

1. Triangular la matriz original con operaciones elementales entre filas hasta que quede triangular superior.
2. La matriz triangular superior resultante es U , a L la construimos agregando en cada columna en el valor L_{ij} el inverso en signo del multiplicador usado para triangular la celda ij .

5.3 Descomposición $PA = LU$

Esta descomposición existe para cualquier matriz cuadrada. Es equivalente al algoritmo de descomposición LU , pero se aplica previamente una permutación expresada con el producto con una matriz P .

6. Descomposición Cholesky $A = \hat{L}\hat{L}^T$

6.1 Existencia

La descomposición de Cholesky $A = \hat{L}\hat{L}^T$ existe si y sólo si A es simétrica y definida positiva.

- A simétrica: $A^T = A$
- A definida positiva: $x^T A x > 0$ para todo $x \neq 0$

Es decir, para cualquier matriz cuadrada real A tal que $a_{ij} = a_{ji}$ y $x^T A x > 0$ para todo vector $x \neq 0$, se puede escribir A como el producto de una triangular inferior $\hat{L}$ y su transpuesta.

Unicidad La factorización es única cuando A es definida positiva y simétrica.

6.2 Algoritmo

1. Calculo $A = LU$
2. Defino D de la siguiente forma:

$$D_{ij} = \begin{cases} U_{ii} & \text{si } i=j \\ 0 & \text{cc.} \end{cases}$$

3. Defino D_1 de tal forma que $D_1 * D_1 = D$, o sea: $(D_1)_{ii} = \sqrt{D_{ii}}$
4. Defino $\hat{L} = L * D_1$
5. Luego $\hat{L}^T$ es simplemente tomar la transpuesta de la calculada en el paso anterior y tengo $A = \hat{L}\hat{L}^T$

7. Descomposición $A = QR$

7.1 Existencia

La descomposición $A = QR$ existe para cualquier matriz $A \in \mathbb{R}^{m \times n}$ con $m \geq n$ y rango completo de columnas (columnas linealmente independientes). Si A no tiene rango completo, aún se puede realizar la descomposición pero algunas filas de R serán nulas. - **Para matrices cuadradas ($m = n$):** Siempre se puede hacer $A = QR$. - **Para matrices rectangulares ($m > n$):** Q será $m \times m$ ortogonal/unitaria y R será $m \times n$ (puede tener ceros al final).

Podemos calcularla usando Gram-Schmidt o Householder.

Propiedad

$Im(Q)$ pero la transformación lineal es distinta, es decir, generalmente $Ax \neq Qx$ $Im(A) =$

Unicidad QR es única si y solo si A tiene columnas LI o también $R_{ii} > 0$.

7.1 Algoritmo Householder

1. Tenemos A y tomamos v_i como la i -ésima columna de A $v_i = (A[i:][1])$ y

$$w_i = \begin{bmatrix} \|v_i\| \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

2. Definimos $u = \frac{v-w}{\|v-w\|}$
3. Definimos $H_{u_i} = I - 2u_i u_i^T$
4. Vemos

$$A' = H_{u_i} A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & H_{21} & H_{22} \\ 0 & H_{23} & H_{24} \end{bmatrix}$$

5. Repito el paso hasta tener A' diagonal superior (la llamo R),
6. Defino $Q = H_r * \dots * H_2 * H_1$
7. Luego $A = H_r * \dots * H_2 * H_1 * R = QR$

7.3 Algoritmo con Gram-Schmidt

1. Calculo una b.o.n. a partir de A y obtengo Q unitaria de la forma:

$$Q = [q_1 \mid \dots \mid q_n]$$

Con $q_i = \frac{v_i}{\|v_i\|}$, siendo v_i vectores ortogonales.

2. Defino la matriz triangular superior R como $R = Q^T A$

$$R = \begin{pmatrix} \mathbf{q}_1^T \mathbf{a}_1 & \mathbf{q}_1^T \mathbf{a}_2 & \mathbf{q}_1^T \mathbf{a}_3 & \cdots \\ 0 & \mathbf{q}_2^T \mathbf{a}_2 & \mathbf{q}_2^T \mathbf{a}_3 & \cdots \\ 0 & 0 & \mathbf{q}_3^T \mathbf{a}_3 & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix}$$

Donde los elementos en la diagonal son $r_{kk} = \|\mathbf{v}_k\|$.

8. Teoremas y propiedades

- A simétrica $\rightarrow \det(A) = \prod_i \lambda_i$
- A cuadrada $\Rightarrow \sum_{i=0}^n \lambda_i = \text{traza}(A)$
- A diagonal o triangular $\Rightarrow$ Los autovalores están en la diagonal
- λ autovalor de A (invertible) $\Rightarrow$

$1/\lambda$ autovalor de A^{-1} y $mg_A(\lambda) = mg_{A^{-1}}(1/\lambda)$ (solo porque son el mismo subespacio, la algebraica no se conserva)

- λ autovalor de $A \Rightarrow \lambda^k$ autovalor de A^k
- $e \in \ker(A^T) \Leftrightarrow e \perp \text{col}(A)$
- D matriz diagonal $\Rightarrow \|D\|_2 = \max_{\lambda} \{|\lambda| : \lambda \text{ autovalor de } D\} = \max |D_{ii}|$

8.1. Definida positiva

- A es definida positiva $\Leftrightarrow$ Para todo vector no nulo $\mathbf{x} \in \mathbb{R}^n$, se cumple que la forma cuadrática $\mathbf{x}^T A \mathbf{x} > 0$.
- A es definida positiva $\Leftrightarrow$ Todos los autovalores de A son estrictamente positivos ($\lambda_i > 0$).
- A es definida positiva $\Leftrightarrow A = LU$ con $U_{ii} > 0$ para $\forall i \in \{1..n\}$
- A es definida positiva $\Leftrightarrow$ Todos los menores principales de A (determinantes de submatrices $k \times k$ superiores izquierdas) son estrictamente positivos ($\det(A_k) > 0$ para $k = 1, \dots, n$).

8.3 Semidefinida positiva

- A es semidefinida positiva $\Leftrightarrow \lambda_i \geq 0$ (autovalores de A)

8.3. Diagonalizable

- $A \in \mathbb{R}^{n \times n}$
- $\lambda_i \in \text{mg}_A(\lambda) = \text{ma}_A(\lambda)$
- $A = P D P^{-1}$, $D \in \mathbb{R}^{n \times n}$
- $A^m = P D^m P^{-1}$
- $A \in \mathbb{R}^{n \times n}$
- $A \in \mathbb{R}^{n \times n}$

8.4. Multiplicidades

- $\text{mg}_a(\lambda) = \dim(E_\lambda)$
- $\text{ma}_a(\lambda) =$ multiplicidad de λ en el polinomio característico (cuántas veces aparece como autovalor).
- $1 \leq \text{mg}_a(\lambda) \leq \text{ma}_a(\lambda)$

- $A \in \mathbb{K}^{N \times N} \implies \sum_i m_a(\lambda_i) = N$

8.5. Matrices semejantes

- $A, B \in K^{N \times N}$ son semejantes $\Leftrightarrow \exists c \in K^{N \times N}$ tal que $A = CBC^{-1}$
- $A = CBC^{-1}$