

Contents

Temas segundo parcial	1
1.  Existencia de Descomposiciones Matriciales	2
2. ¿Cómo diagonalizo una matriz?	3
2.1 Existencia	3
2.2 Procedimiento:	3
2.3 Observación:	3
3. Descomposición Shur	3
3.1 Procedimiento:	3
4. Descomposición SVD	4
4.1 Observaciones:	4
4.2 Procedimiento:	4
4.3 Propiedades para $A = U\Sigma V^*$	4
5. Procesos de Markov.	6
6. Cuadrados mínimos	6
7. Métodos Iterativos. Convergencia.	7
7.7 Más propiedades	9

Temas segundo parcial

1. Existencia de Descomposiciones Matriciales

Descomposición	Forma	Tipo de Matriz Requerida	¿Existe para Toda Matriz A ?	Notas Clave
SVD (Valores Singulares)	$A = U\Sigma V^*$	Ninguna (Cualquier matriz $m \times n$).	SÍ 	Es la factorización más general y universal.
Schur (Triangularización)	$A = UTU^*$	Cuadrada ($n \times n$).	SÍ (Si es cuadrada) 	T es triangular superior y U es unitaria.
QR (Ortogonal/Triangular)	$A = QR$	Ninguna (Cualquier matriz $m \times n$ con $m \geq n$).	SÍ 	Q es ortogonal/unitaria, R es triangular superior.
LU (Lower/Upper)	$A = LU$	Cuadrada ($n \times n$).	NO 	Solo existe si todos los menores principales son distintos de cero. Siempre existe con permutación: $PA = LU$.
Cholesky	$A = LL^*$ (LL^T)	(o Cuadrada ($n \times n$), Hermitiana (Simétrica), y Definida Positiva).	NO 	Es la descomposición más restrictiva. Es única si existe.

2. ¿Cómo diagonalizo una matriz?

2.1 Existencia

A diagonalizable

$\Leftrightarrow$ Los vectores columna de A forman una base

$\Leftrightarrow$ Existen n autovectores LI (vectores columna de A)

$\Leftrightarrow$ Para todo λ_i autovalor de A , vale que $mg_A(\lambda_i) = ma_A(\lambda_i)$

$\Leftrightarrow$ Es semejante a una matriz diagonal

$$\Leftrightarrow A = PDP^{-1}$$

$$\Leftrightarrow A^m = PD^m P^{-1}$$

2.2 Procedimiento:

1. Determinar si A es diagonalizable.
2. Hallar autovalores $\lambda_1, \dots, \lambda_n$ de A .
3. Definir

$$D = \begin{pmatrix} \lambda_1 & 0 & \dots & 0 & 0 \\ 0 & \lambda_2 & \dots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \vdots & \vdots & \vdots & \vdots & \lambda_n \end{pmatrix}$$

4. Hallar autovectores $v_1, \dots, v_n$ de A .
5. Definir $Q = (v_1 \mid \dots \mid v_n)$.
6. Escribir $A = QDQ^*$

2.3 Observación:

En toda diagonalización de una matriz, la diagonal tiene los autovalores de esa matriz.

3. Descomposición Shur

- Toda matriz A es unitariamente semejante a una matriz triangular superior ($\exists U$ unitaria y T triangular: $A = UTU^*$).
- Cualquier matriz cuadrada A puede ser escrita como $A = QUQ^*$, con Q matriz unitaria ($Q^* = Q^{-1}$) y D diagonal.

3.1 Procedimiento:

1. Encontrar un autovector
2. Completar una b.o.n para Q_1 con el autovector
3. Calcular $Q_1^* A Q_1$
4. Repetir los pasos anteriores para la submatriz del resultado, pisando los valores en las submatrices de Q y A .

4. Descomposición SVD

La descomposición en valores singulares de una matriz $A \in \mathbb{C}^{m \times n}$ es un producto de la forma

$$A = U\Sigma V^*$$

Con: - $U \in \mathbb{C}^{m \times m}$: Las columnas $u_1, \dots, u_m$ vienen dadas por la relación $Av_j = \sigma_j u_j$ con $j = 1 \dots n$. - $V \in \mathbb{C}^{n \times n}$: Las columnas son los autovectores (de A^*A). - $\Sigma \in \mathbb{C}^{m \times n}$: Diagonal real y no negativa.

Pueden pasar dos casos: - $m > n$: En tal situación se completan las columnas de U para tener una b.o.n en $\mathbb{C}^m$. - $m < n$: Hay varios v_j asociados a un autovalor 0. Si $\sigma_j = 0$ para algun $j \leq \min(n, m)$ entonces se puede elegir u_j completando la ortonormalidad de las columnas de U .

4.1 Observaciones:

- $A^*A = (U\Sigma V^*)^*U\Sigma V^* = V\Sigma^*U^*U\Sigma V^* = V\Sigma^*\Sigma V^*$
- $AA^* = U\Sigma V^*(U\Sigma V^*)^* = U\Sigma V^*V\Sigma^*U^* = U\Sigma\Sigma^*U^*$
- Como Σ es diagonal:
 - Si es cuadrada vale que $\Sigma^*\Sigma = \Sigma^2$.
 - $\Sigma^*\Sigma$ y $\Sigma\Sigma^*$ son semejantes a Σ^2 .
- Calcular SVD para A^* sale de $A^* = (U\Sigma V^*)^* = V\Sigma^t U^*$

4.2 Procedimiento:

Sea $A \in \mathbb{C}^{m \times n}$: 1. Calcular A^*A (o AA^*) 2. Calcular los autovalores y autovectores de A^*A 3. Formar las matrices U, Σ, V^T : - V son los autovectores normalizados de A^*A . - Σ es la matriz diagonal $\mathbb{C}^{m \times n}$ con los $\sigma_i = \sqrt{\lambda_i}$ (de A^*A o AA^*). - U la calculamos con la relación $Av_i = \sigma_i u_i$ para cada v_i ($i = 1 \dots n$) y luego completando una base ortonormal de para $u_n \dots u_m$.

4.3 Propiedades para $A = U\Sigma V^*$

Sea también $r = rk(A) = \#\{\sigma_i \in \mathbb{K}_{\neq 0} : \text{valores singulares no nulos de } A\}$

- $\|A\|_2 = \sigma_1(A)$
- A es matriz invertible (rango completo y cuadrada) $\rightarrow \text{cond}_2(A) = \frac{\sigma_{\max}}{\sigma_{\min}} = \frac{\sigma_1}{\sigma_n}$
- En términos de SVD ($A = U\Sigma V^T$), una matriz es ortogonal si y solo si todos sus **valores singulares son iguales a 1** ($\Sigma = I$).
- $\max_{\|x\|_2=1} \|Ax\|_2 = \|A\|_2 = \sigma_1$

Demo:

$$\begin{aligned}
& \max_{\|x\|_2=1} \|Ax\|_2 = \\
& \max_{\|x\|_2=1} \|U\Sigma V^*x\|_2 = \\
& \max_{\|x\|_2=1} \|\Sigma V^*x\|_2 = \\
& \max_{\|x\|_2=1} \|\Sigma y\|_2 = \\
& \sum_{i=1}^n \sigma_i^2 y_i^2 \\
& \leq \sigma_1^* \sum_{i=1}^n y_i^2 = \sigma_1^* \|y\|_2^2 \\
& = \sigma_1
\end{aligned}$$

- $\min_{\|x\|_2=1} \|Ax\|_2 = \sigma_n$

Demo:

$$\begin{aligned}
& \max_{\|x\|_2=1} \|Ax\|_2 = \\
& \max_{\|x\|_2=1} \|U\Sigma V^*x\|_2 = \\
& \max_{\|x\|_2=1} \|\Sigma V^*x\|_2 = \\
& \max_{\|x\|_2=1} \|\Sigma y\|_2 = \\
& \sum_{i=1}^n \sigma_i^2 y_i^2 \\
& \geq \sigma_n^* \sum_{i=1}^n y_i^2 = \sigma_n^* \|y\|_2^2 \\
& = \sigma_n
\end{aligned}$$

- $Im(A) = \langle u_1, \dots, u_r \rangle$
- $Im(A^t) = \langle v_1, \dots, v_r \rangle$
- $Nu(A) = \langle v_{r+1}, \dots, v_n \rangle$
- $Nu(A^t) = \langle u_{r+1}, \dots, u_m \rangle = Nu(A^t A)$

Tipo de Matriz	Condición de Forma Cuadrática	Condición de Autovalores (λ_i)	Consecuencia en $\det(A)$
Definida Positiva (DP)	$x^*Ax > 0$ para todo $x \neq 0$	Todos $\lambda_i > 0$	$\det(A) > 0$
Semidefinida Positiva (SDP)	$x^*Ax \geq 0$ para todo x	Todos $\lambda_i \geq 0$	$\det(A) \geq 0$

5. Procesos de Markov.

5.1 Proceso de Markov

$$v^{(k+1)} = Av^{(k)}$$

5.2 Matriz de transición

Una matriz de transición A cumple las siguientes propiedades: - $A_{ij} \geq 0$ - $\sum_i A_{ij} = 1, \forall j$ - 1 es autovalor de A . - Si λ es autovalor entonces $|\lambda| < 1$. - $mg(\lambda) = ma(\lambda)$ - No toda matriz de Markov es diagonalizable, pero si lo es $A = PDP^{-1} \rightarrow v^{(k+1)} = A^k v^{(0)} = PD^k P^{-1} v^{(0)}$

5.3 Existencia de estado límite/equilibrio

Un vector v se dice estado de equilibrio si $Av = v$. Es un autovector asociado para $\lambda = 1$. Toda matriz de Markov tiene estado de equilibrio: $Av^* = v^*$

5.4 Convergencia de estado límite/equilibrio

El método ($v^{(k+1)} = Av^{(k)}$) converge para cualquier

$$v^{(0)} \Leftrightarrow$$

$$\exists! \lambda_i : \text{autovalor de } A \text{ tal que } (\lambda_i = 1 \wedge (\forall \lambda_j : \text{autovalor de } A: \lambda_j \neq \lambda_i \rightarrow |\lambda_j| < 1))$$

$$\Leftrightarrow \exists A^{\text{inf}}$$

$\Leftrightarrow$ La cadena de Markov asociada es irreducible

5.5 Cadenas reducibles o irreducibles

- Se dice que una **cadena de Markov es irreducible** si $\dim(Ker(A - I)) = \dim(E_A(\lambda = 1)) = 1$.
- Si la **cadena de Markov es reducible** ($\dim(E_A(\lambda = 1)) > 1$) entonces la convergencia depende de $v^{(0)}$.

Si $v^{(0)}$ es ortogonal a los autovectores asociados a los autovalores de módulo 1, entonces $v^{(k)}$ sí puede converger. Si $v^{(0)}$ tiene componente en dirección de esos autovectores, entonces $v^{(k)}$ no converge (por ejemplo, oscila).

6. Cuadrados mínimos

Queremos aproximar una solución de $Ax = b$.

$$\|Ax - b\| \rightarrow 0$$

Para resolverlo usamos ecuaciones normales

$$A^t A x = A^t b$$

$$x = (A^t A)^{-1} A^t b$$

Props: - Si existen soluciones para $Ax = b \rightarrow z = A^t b$ es solución. Si hay infinitas soluciones, $z = A^t b$ es la solución de norma 2 mínima. - $Ax = b$ tiene solución $\Leftrightarrow AA^t b = b$ - Las ecuaciones normales no están bien condicionadas por eso las soluciones usan QR o SVD ($\text{cond}(A^t A) = \text{cond}_2(A)^2$ y $\text{cond}_2(A) = \frac{\sigma_1}{\sigma_n}$). - A tiene columnas LI $\Leftrightarrow$ Cuadrados mínimos tiene única solución.

Desarrollo de la fórmula: - Aparece minimizando una función de error $L(y, \hat{y}) = (y - \hat{y})^2$ o también $E = \sum_{i=1}^n (y_i - \hat{y}_i)^2$. - Luego, buscamos...

$$\text{argmin}_{a,b} E(a,b) = \text{argmin}_{a,b} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \text{argmin}_{a,b} \sum_{i=1}^n (y_i - (a^* x_i + b))^2$$

- O también, matricialmente.. $\|Ax - b\|_2^2 = \|A\hat{x} - b\|_2^2 = \|A\hat{x} - b\|_2^2$

Si llamamos $\hat{X}$ a los parámetros

$$\begin{pmatrix} a \\ b \end{pmatrix}$$

entonces la solución aproximada queda..

$$\text{argmin}_{\hat{X}} \| (A\hat{X} - b) \|_2^2$$

7. Métodos Iterativos. Convergencia.

$$A = D + L + U$$

Definimos un método iterativo de la siguiente forma...

$$X = TX + c$$

Teo: x^n converge $\Leftrightarrow \rho(T) < 1$

Con: $\rho(T) = \max |\lambda| : \lambda \text{ autovalor de } T$

A veces se escribe $B = T$, como la matriz de iteración.

7.1 Método Jacobi

$$Ax = (D + L + U)x = Dx + (L + U)x = b$$

$$Dx = -(L + U)x + b$$

$$x = -D^{-1}(L + U)x + D^{-1}b$$

$$x^{(n+1)} = -D^{-1}(L + U)x^{(n)} + D^{-1}b$$

- Puede paralelizarse ...

```
def metodoJacobi(A: np.ndarray, b: np.ndarray, epochs: int) -> np.ndarray:
    """
    Estima la solución x usando
     $x^{(n+1)} = -D^{-1}(L+U)x^{(n)} + D^{-1}b$ 

    Parámetros
    -----
    - A: np.ndarray
      Matriz del sistema
    - b: np.ndarray
      Solucion a partir del vector x
    - epochs: int
      Cantidad de iteraciones del método

    Retorna
    -----
    - x: np.ndarray
      Solucion estimada de x
    """
    m, n = A.shape

    D, L, U = splitMatrix(A)
    D_inv = alc.inv(D)
    Bj = -D_inv@(L+U)
    c = D_inv@b

    x = np.random.random((n, 1))
    for i in range(epochs):
        x = Bj @ x + c
    return x
```

7.2 Método Gauss-Seidel

$$Ax = (D + L + U)x = (D + L)x + Ux = b$$

$$(D + L)x = -Ux + b$$

$$x = -(D + L)^{-1}Ux + (D + L)^{-1}b$$

$$x^{(n+1)} = -(D + L)^{-1}Ux^{(n)} + (D + L)^{-1}b$$

- No puede implementarse de manera paralelizada.

```
def metodoGaussSeidel(A: np.ndarray, b: np.ndarray, epochs: int) -> np.ndarray:
    """
    Estima la solución x usando
     $x^{(n+1)} = -(D+L)^{-1}Ux^{(n)} + (D+L)^{-1}b$ 

    Parámetros
    -----
```



```

- A: np.ndarray
    Matriz del sistema
- b: np.ndarray
    Solucion a partir del vector x
- epochs: int
    Cantidad de iteraciones del método

Retorna
-----
- x: np.ndarray
    Solucion estimada de x
"""
m, n = A.shape

D, L, U = splitMatrix(A)
Aux_inv = alc.inv(D+L)
Bgs = -Aux_inv@U
c = Aux_inv@b

x = np.random.random((n, 1))
for i in range(epochs):
    x = Bgs @ x + c
return x

```

7.3 Método SOR

s

7.4 Método gradiente

s

7.5 Propiedades

- $T = -M^{-1}N \wedge \lambda$ autovalor de $T \Leftrightarrow \det(\lambda M + N) = 0$
- El método converge en n pasos si $x^{n+1} = x^n \Leftrightarrow T^{n+1} = 0$.
- A matriz cuadrada y tridiagonal, entonces $\rho(B_{GS}) = \rho(B_j)^2$
- Para toda norma subordinada $\| \cdot \|$ vale que: $\rho(B) = \lim_{n \rightarrow \infty} \| B^n \|^{1/n}$

7.6 Radio espectral

El radio espectral $\rho(T)$ de la matriz de iteración T determina si un método iterativo converge y qué tan rápido lo hace. - Si $\rho(B) < 1$: el método converge . - Si $\rho(B) = 1$: puede no converger o converger muy lentamente. - Si $\rho(B) > 1$: el método diverge . - Cuanto menor sea $\rho(B)$, más rápida será la convergencia .

7.7 Más propiedades

- A es hermitiana $\Leftrightarrow A = A^*$.
- Las matrices hermitianas tienen autovalores reales y son diagonalizables ortogonalmente con $A = UDU^*$

- Las matrices hermitanas son un subconjunto de las normales.
- A hermitiana $\rightarrow$ todo sus autovectores son ortogonales entre si.
- A simétrica real $\rightarrow A$ hermitana.
- A es normal $\Leftrightarrow A^* A = A A^*$
- Teorema Espectral: Si A es normal, entonces se puede diagonalizar en una b.o.n como $A = Q D Q^*$.
- $A^t A$ es simétrica
- $\max ||Ax||_2 = \max_i |\sigma_i|$
- $\min ||Ax||_2 = \min_i |\sigma_i|$
- $||UA|| = ||A||$, U matriz unitaria
- Si M es real y simétrica y v, w son autovectores de autovalores diferentes, entonces v, w son ortogonales.
- Pseudoinversa: $A^+ = (A^t A)^{-1} A^t$